

Przetwarzanie i analiza danych

Larisa Dobryakova, Wydział Informatyki, ZUT

1 Rachunek prawdopodobieństwa

Prawdopodobieństwo sumy zdarzeń losowych A i B wykluczających:

$$P(A \cup B) = P(A) + P(B) \quad (1)$$

Prawdopodobieństwo iloczynu dwóch zdarzeń A i B jest równe iloczynowi jednego z nich oraz prawdopodobieństwa warunkowego drugiego (czyli pod warunkiem, że pierwsze z nich zaszło):

$$P(A \cap B) = P(A) P(B|A) \quad (2)$$

Prawdopodobieństwo całkowite. Jeżeli zdarzenia $A_1, A_2, \dots, A_n$ wykluczają się parami i mają prawdopodobieństwa dodatnie, to dla każdego zdarzenia B , zawartego w sumie zdarzeń $A_1 \cup A_2 \cup \dots \cup A_n$:

$$P(B) = P(B|A_1)P(A_1) + P(B|A_2)P(A_2) + \dots + P(B|A_n)P(A_n) \quad (3)$$

Twierdzenie Bayesa – twierdzenie teorii prawdopodobieństwa, wiążące prawdopodobieństwa warunkowe dwóch zdarzeń warunkujących się nawzajem, sformułowane przez Thomasa Bayesa:

$$P(A|B) = \frac{P(A) P(B|A)}{P(B)} \quad (4)$$

Zadanie 1.1. Student zdaje egzamin, który wygląda następująco: są przygotowane dwie urny (I – łatwiejsza i II trudniejsza) w każdej 10 pytań, egzaminator rzuca kostką do gry – jeżeli wypadnie 1, to losuje pytanie z urny I, w przeciwnym przypadku losuje pytanie z urny II. Wiadomo, że student zna odpowiedź na 9 pytań z urny I oraz na 2 pytania z urny II.

Następnego dnia okazuje się, że student jednak zdał egzamin. Jakie jest tego prawdopodobieństwo?

Nie może sobie jednak przypomnieć, którą urnę wylosował. Co jest bardziej prawdopodobne, że odpowiedział na pytanie trudniejsze, czy łatwiejsze?

A gdyby student nie zdał egzaminu: co jest tego przyczyną?

Jakie jest prawdopodobieństwo tego, że nie odpowiedział na pytanie prostsze z urny I?

Zadanie 1.2. Danych jest $N + 1$ urn, w i -tej urnie ($i = 0, 1, \dots, N$) jest i kul białych oraz $(N - i)$ kul czarnych. Wylosowano urnę, a następnie z tej urny wylosowano jedną kulę. Jaka jest szansa, że wylosowano kulę białą?

Zadanie 1.3. Na 100 mężczyzn 5, a na 1000 kobiet 2 nie rozróżniają kolorów. Z grupy o jednakowej liczbie mężczyzn i kobiet wybrano losową jedną osobę, która okazała się daltonistą. Jakie jest prawdopodobieństwo tego, że jest to mężczyzna?

Zadanie 1.4. Co jest bardziej prawdopodobne: wygrać z równorzędnym przeciwnikiem dwie partie z trzech czy trzy z pięciu:

- (a) partii zakończonych remisem nie bierzemy pod uwagę
- (b) partię zakończoną remisem bierzemy pod uwagę i zaliczamy je do porażki?

Zadanie 1.5. Problem Monty’ego Halla. Prowadzący ukrył nagrodę w jednym z trzech pudełek. Wybieramy pudełko, ale nie otwieramy go, następnie prowadzący otwiera jedno z pustych pudełek i daje możliwość zmiany pudełka na drugie nieodkryte lub pozostania przy swoim wyborze. Należy rozstrzygnąć co się bardziej opłaca:

- (a) zmienić pudełko na drugie nieodkryte
- (b) pozostać przy swoim dotychczasowym wyborze
- (c) bez znaczenia.

2 Entropia

Niech X i Y są zmiennymi losowymi, przyjmującymi odpowiednie wartości $x_1, x_2, \dots, x_n, y_1, y_2, \dots, y_m$ z prawdopodobieństwami $p_1(x), p_2(x), \dots, p_n(x)$ i $p_1(y), p_2(y), \dots, p_m(y)$.

Prawdopodobieństwa łączne $p(x_i, y_j)$.

Entropia – miara niepewności występowania losowego zdarzenia X :

$$H(X) = - \sum_{i=1}^n p(x_i) \log p(x_i) \quad (5)$$

W przypadku, gdy $p(x_i) = 0$ dla pewnego x_i wynik logarytmowania $\log 0$ jest nieokreślony, ale nie stanowi to ograniczenia, ponieważ wartość składnika $0 \log 0$ jest przyjmowana jako 0, co jest zgodne z granicą $\lim_{p \rightarrow 0+} p \log p = 0$.

$$H(XY) = - \sum_{i=1}^n \sum_{j=1}^m p(x_i, y_j) \log p(x_i, y_j) \quad (6)$$

Entropia warunkowa zdarzenia Y pod warunkiem zajścia zdarzenia X :

$$H(Y|X) = \sum_{i=1}^n p(x_i) H(Y|x_i) \quad (7)$$

Entropia warunkowa zdarzenia Y pod warunkiem, że zdarzenie X **przyjęło wartość** x_i :

$$H(Y|x_i) = - \sum_{j=1}^m p(y_j|x_i) \log p(y_j|x_i). \quad (8)$$

Informacja wzajemna – miara zależności pomiędzy dwiema zmiennymi losowymi.

$$I(XY) = \sum_{i=1}^n \sum_{j=1}^m p(x_i, y_j) \log \frac{p(x_i, y_j)}{p(x_i)p(y_j)}. \quad (9)$$

Zadanie 2.1. Uzasadnić następujące własności ($X \perp Y$ oznacza, że atrybuty są niezależne):

- (a) $I(XY) = H(X) + H(Y) - H(XY) = H(Y) - H(Y|X) = H(X) - H(X|Y)$
- (b) $X \perp Y \Rightarrow H(XY) = H(X) + H(Y)$
- (c) $X \perp Y \Rightarrow I(XY) = 0$
- (d) $0 \leq H(X) \leq \log_2(n)$
- (e) $0 \leq I(XY) \leq H(Y)$

Zadanie 2.2. Pewna zmienna losowa X może przyjąć wartości $\{0, 1, 2\}$. Rzucamy symetryczną monetą. Jeśli wypadnie orzeł, to zmiennej przypisujemy wartość 0, jeśli nie, ponownie rzucamy monetą. Gdy ponownie wypadnie orzeł przypisujemy zmiennej wartość 1, w przeciwnym przypadku 2. Wyznaczyć entropię zmiennej X .

Zadanie 2.3. Tabela 1 przedstawia prawdopodobieństwa łączne dwóch zmiennych X i Y . Wyznaczyć $H(X)$, $H(Y)$, $H(X|Y)$, $H(Y|X)$, $H(X, Y)$, $I(X, Y)$.

$p(x, y)$	$x = 1$	$x = 2$	$x = 3$	$x = 4$
$y = 1$	$\frac{1}{8}$	$\frac{1}{16}$	$\frac{1}{32}$	$\frac{1}{32}$
$y = 2$	$\frac{1}{16}$	$\frac{1}{8}$	$\frac{1}{32}$	$\frac{1}{32}$
$y = 3$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$
$y = 4$	$\frac{1}{4}$	0	0	0

Tabela 1: Prawdopodobieństwa łączne X i Y

Zadanie 2.4. Na podstawie danych z tabeli 2 wyznaczyć ile informacji na temat atrybutu Y dostarcza informacja atrybutu X .

	$x = 0$	$x = 1$
$y = 0$	71	10
$y = 1$	17	3

Tabela 2: Dane dla atrybutów X i Y

3 Przetwarzanie wstępne i wizualizacja

Zadanie 3.1. Dla zbioru danych z tabeli 3 wykonać następujące działania:

- (a) zdyskretyzować zmienną temperatura pod warunkiem uszkodzeń (uwzględniając tylko i wyłącznie fakt występowania chociażby jednego uszkodzenia);
- (b) zapisać w postaci tabeli kontyngencji rozkład licznosci tych dwóch zmiennych;
- (c) znaleźć rozkład częstości i rozkłady brzegowe tych dwóch atrybutów;
- (d) porównać empiryczny rozkład częstości z rozkładem produktowym: postawić test χ^2 o zależności zmiennych.

nr	Liczba uszkodzeń	Temperatura (F)
1	0	66
2	1	70
3	0	69
4	0	68
5	0	67
6	0	72
7	0	73
8	0	70
9	1	57
10	1	63
11	1	70
12	0	78
13	0	67
14	2	53
15	0	67
16	0	75
17	0	70
18	0	81
19	0	76
20	0	79
21	2	75
22	0	76
23	1	58

Tabela 3: Liczba uszkodzeń w zależności od temperatury (źródło: challengerRing)

4 Metoda największej wiarygodności (MNW)

Założmy, że jest K interesujących nas nieznanymi parametrów w_k i tworzą one zbiór:

$$w = \{w_1, w_2, \dots, w_K\}, k = 1, 2, \dots, K \quad (10)$$

Niech

$$x = (x_1, x_2, \dots, x_n)^T \quad (11)$$

jest pewna próba reprezentująca zmienną losową X , rozkład której określony przez funkcję $p(x, w)$. Funkcja $p(x, w)$ jest prawdopodobieństwem w przypadku zmiennej dyskretnej lub gęstością prawdopodobieństwa w przypadku zmiennej ciągłej.

Niech pojedyncze i -te doświadczenie, czyli pobranie próby o liczebności 1, daje w wyniku x_i , wtedy dla próby n -wymiarowej (liczby doświadczeń n , serii n wyników) funkcja wiarygodności jest określona jako iloczyn prawdopodobieństw:

$$L(x, w) = \prod_{i=1}^n p(x_i, w) \quad (12)$$

Ponieważ funkcja $L(x, w)$ osiąga maksimum w tych samych punktach, co jej logarytm, w praktyce często wykorzystuje się logarytmiczna funkcja wiarygodności:

$$l(x, w) = \ln(L(x, w)) = \ln\left(\prod_{i=1}^n p(x_i, w)\right) = \sum_{i=1}^n \ln p(x_i, w). \quad (13)$$

Estymatorem maksymalnej wiarygodności nazywa się zbiór parametrów w^* , dla którego logarytmiczna funkcja wiarygodności osiąga maksymalną wartość:

$$w^* = \arg \max_w l(x, w) \quad (14)$$

W tym celu należy pierwszą pochodną logarytmicznej funkcji wiarygodności l względem parametrów w_k przyrównać do zera:

$$\frac{\partial l}{\partial w} = 0 \quad (15)$$

i rozwiązać układ K równań według parametrów w .

Zadanie 4.1. Rzucamy n razy niesymetryczną monetą (prawdopodobieństwo orła p), k razy wypadł orzeł ($n - k$) razy – reszka. Znaleźć estymator parametru p , stosując MNW.

Zadanie 4.2. Wykorzystując MNW, ocenić parametr p rozkładu geometrycznego

$$P(X = x_i) = (1 - p)^{(x_i-1)}p \quad (16)$$

zmiennej losowej X na podstawie próby $x_1, x_2, \dots, x_n$, gdzie x_i – liczba doświadczeń wykonanych do występowania zdarzenia, p – prawdopodobieństwo występowania zdarzenia w jednym doświadczeniu.

Zadanie 4.3. Zmienna losowa na rozkład:

$$P(x_k = k) = \binom{n}{k} p^k (1 - p)^{n-k} \quad (17)$$

Wykorzystując MNW znaleźć estymator parametru p na podstawie próby 52, 48, 49, 52, 50, 47, 48, $n = 65$.

Zadanie 4.4. Wykorzystując MNW, ocenić parametr λ rozkładu Poissona:

$$P_m(X = x_i) = \frac{\lambda^{x_i} e^{-\lambda}}{x_i!} \quad (18)$$

zmiennej losowej X na podstawie próby $x_1, x_2, \dots, x_n$, gdzie x_i – liczba wystąpień niezależnych zdarzeń w i -tym doświadczeniu.

Zadanie 4.5. Wykorzystując metodę największej wiarygodności, ocenić parametr p dwumianowego rozkładu Bernoullego:

$$P_n(k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad (19)$$

jeśli przy n_1 niezależnych doświadczeniach zdarzenie A występowało k_1 razy, a przy n_2 niezależnych doświadczeniach zdarzenie A występowało k_2 razy.

Zadanie 4.6. Wykorzystując metodę największej wiarygodności, ocenić parametr w na podstawie próby:

1, 4 1, 5 3, 2 1, 4 2, 5 3, 4 3, 1 2, 4 3, 8 2, 6,
jeśli funkcja gęstości ma postać:

$$f(x) = \frac{2x^3}{\sqrt{2\pi}} e^{-\frac{(x^4-w)^2}{2}} \quad (20)$$

Zadanie 4.7. Wykorzystując MNW, ocenić parametr λ na podstawie różnych prób pod warunkiem, że ciągła zmienna losowa ma gęstość prawdopodobieństwa:

$$f(x) = \lambda e^{\lambda(x-20)} \quad (21)$$

Próba 1: 3, 4, 5, 10, 8, 7, 6, 15, 18.

Próba 2:

nr	x_j	n_j
1	3	1
2	5	2
3	7	6
4	9	7
5	11	5
6	13	3
7	15	1

Próba 3:

nr	x_j	n_j
1	1-3	5
2	3-5	6
3	5-7	7
4	7-9	15
5	9-11	22
6	11-13	27
7	13-15	30
8	15-17	34
9	17-19	35

5 Klasteryzacja

Zadanie 5.1. Dane są punkty $x_1, x_2, \dots, x_n$. Znaleźć taki punkt c , dla którego suma kwadratów odległości punktów x_i od punktu c jest najmniejsza.

Zadanie 5.2. Dane są punkty $x_1, x_2, \dots, x_n$. Znaleźć taki punkt c , dla którego suma odległości punktów x_i od punktu c jest najmniejsza.

Zadanie 5.3. Niech odległość między skupieniami dana wzorem:

$$d(A, B) = d^2(\bar{A}, \bar{B}) \quad (22)$$

Pokazać, że środek ciężkości po złączeniu skupień będzie równy:

$$\overline{AB} = \frac{n_A \bar{A} + n_B \bar{B}}{n_A + n_B}, \quad (23)$$

gdzie n_A i n_B – liczba elementów w klastrach A i B odpowiednio.

6 Klasyfikacja

Możliwe wyniki klasyfikacji:

- **True–Positive** (TP , prawdziwie pozytywny) – przewidywanie pozytywne, faktycznie zaobserwowana klasa pozytywna;
- **True–Negative** (TN , prawdziwie negatywny) – przewidywanie negatywne, faktycznie zaobserwowana klasa negatywna;
- **False–Positive** (FP , fałszywie pozytywny) – przewidywanie pozytywne, faktycznie zaobserwowana klasa negatywna;
- **False–Negative** (FN , fałszywie negatywny) – przewidywanie negatywne, faktycznie zaobserwowana klasa pozytywna.

Miary jakości klasyfikacji:

1. **Dokładność** (angl. *accuracy*):

$$ACC = \frac{TP + TN}{TP + TN + FP + FN} \quad (24)$$

2. **Błąd klasyfikacji** (angl. *error*):

$$ERR = 1 - ACC = \frac{FP + FN}{TP + TN + FP + FN} \quad (25)$$

3. **Czułość** (angl. *Recall*, *True–Positive Rate*):

$$TPR = \frac{TP}{TP + FN} \quad (26)$$

4. **Specyficzność** (angl. *Specificity*, *True–Negative Rate*):

$$TNR = \frac{TN}{TN + FP} \quad (27)$$

5. **Precyzja** (angl. *Precision*, *Positive Predictive Value*):

$$PPV = \frac{TP}{TP + FP} \quad (28)$$

6. **F₁** (angl. *F₁–score*):

$$F_1 = \frac{2TP}{2TP + FP + FN} \quad (29)$$

7. **Zbalansowana dokładność**:

$$\frac{1}{2}TPR + \frac{1}{2}TNR \quad (30)$$

Zadanie 6.1. Zinterpretować TN , FN , TP , FP na podstawie przykładu klasyfikatora wykrywającego pewną chorobę (tj. 0 – osoba zdrowa, 1 – osoba chora).

Zadanie 6.2. Zinterpretować miary: dokładność klasyfikacji, błąd klasyfikacji, czułość, specyficzność, precyzja na przykładzie klasyfikatora wykrywającego chorobę (tj. 0 – osoba zdrowa, 1 – osoba chora).

Zadanie 6.3. Dla danych z tabeli 4 wykonać następujące działania:

- (a) przyjmując próg 0,5 wyznaczyć macierz konfuzji, dokładność, błąd, czułość, specyficzność, precyzję, zbalansowaną dokładność oraz miarę F_1 ;
- (b) dla kilku wartości progu wyznaczyć czułość oraz specyficzność, a następnie narysować krzywą ROC ;
- (c) na podstawie wyznaczonych punktów na krzywej ROC oszacować miarę AUC .

Klasa	0	1	1	0	1	0	0	1	0	0
Predykcja	0,95	0,8	0,75	0,6	0,55	0,4	0,3	0,25	0,2	0,10

Tabela 4: Dane rzeczywiste oraz wyniki klasyfikacji

Zadanie 6.4. Dla danych z tabel 5, 6 policzyć następujące miary oceny klasyfikacji: dokładność, precyzję, czułość oraz F_1 . Który z klasyfikatorów działa najlepiej?

Klasa ↓ / Predykcja →	0	1
0	140	60
1	20	22

Tabela 5: Klasyfikator 1

Klasa ↓ / Predykcja →	0	1
0	100	100
1	2	40

Tabela 6: Klasyfikator 2

Zadanie 6.5. Pewna choroba występuje u 2 osób na 100. Wiedząc, że czułość klasyfikatora wykrywającego taką chorobę wynosi 0,8, a specyficzność 0,7, wykonać następujące zadania:

- (a) Wy tłumaczyć znaczenie wskaźników czułość i specyficzność dla podanego przykładu.
- (b) Wyznaczyć zbalansowaną dokładność.
- (c) Uzupełnić macierz konfuzji.
- (d) Wyznaczyć dokładność klasyfikacji.
- (e) Wyznaczyć prawdopodobieństwo poprawnego wykrycia choroby, wiedząc, że klasyfikator podjął decyzję o chorobie.
- (f) Wyznaczyć prawdopodobieństwo poprawnego wskazania osoby zdrowej wiedząc, że klasyfikator podjął decyzję o braku choroby.

Zadanie 6.6. Przypuśćmy, że klasyfikujemy pacjenta w ten sposób, że rzucamy symetryczną monetą oraz jeżeli wypadł orzeł diagnozujemy: zdrowy, jeżeli reszka stawiamy diagnozę: chory.

Prawdopodobieństwo poprawnego wykrycia choroby, wiedząc, że klasyfikator podjął decyzję o chorobie jest równe 0,9. Specyficzność klasyfikatora jest równa 0,1.

Wyznaczyć TN , TP , FN , FP , jeśli liczba badanych osób wynosi 1500.

Obliczyć prawdopodobieństwo poprawnego wskazania osoby zdrowej wiedząc, że klasyfikator podjął decyzję o braku choroby.